

Reporte de Fundamentación y Estado del Arte

Proyecto: Poseidón AUV: Plataforma Robótica Autónoma para Inspección y Mantenimiento de Infraestructura Submarina

Fecha de Generación: 24 de October de 2025

Reporte de Fundamentación para el Proyecto Poseidón AUV

1. Marco Teórico

El proyecto Poseidón AUV se fundamenta en la convergencia y aplicación avanzada de conceptos clave en robótica submarina, inteligencia artificial y gestión de datos. Estos pilares teóricos son esenciales para justificar la viabilidad y el potencial innovador de la plataforma propuesta.

1.1. Conceptos Fundamentales

1. Localización y Mapeo Simultáneo (SLAM) en Entornos Submarinos:

- **Explicación:** SLAM es una técnica computacional que permite a un robot construir un mapa de un entorno desconocido mientras, simultáneamente, estima su propia posición dentro de ese mapa. En entornos terrestres, el GPS facilita la localización, pero bajo el agua, donde las señales de radiofrecuencia no penetran, SLAM se vuelve indispensable. Los algoritmos de SLAM procesan datos de diversos sensores (sónar, cámaras, unidades de medición inercial) para crear una representación coherente del espacio y la trayectoria del vehículo.
- **Relevancia para Poseidón AUV:** La capacidad de Poseidón para operar a profundidades de hasta 500 metros y realizar inspecciones detalladas sin depender de una infraestructura de posicionamiento externa es crítica. El SLAM autónomo basado en sonar de barrido lateral y multihaz (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"; Fuente: Arxiv, Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization") permitirá al AUV navegar de forma segura y construir modelos 3D precisos de las infraestructuras y el lecho marino, un requisito fundamental para el mapeo y la detección de anomalías.

2. Visión por Computadora y Aprendizaje Profundo para Detección de Anomalías:

- **Explicación:** La Visión por Computadora (Computer Vision) se refiere a la capacidad de los sistemas informáticos para "ver" e interpretar el mundo visual. El Aprendizaje Profundo (Deep Learning), una subdisciplina del Machine Learning, ha revolucionado este campo mediante el uso de redes neuronales artificiales con múltiples capas para aprender representaciones complejas directamente de los datos

(imágenes y videos). Esto permite la detección automática de objetos, la segmentación y la clasificación.

● **Relevancia para Poseidón AUV:** La inspección visual detallada es un componente central del proyecto. La aplicación de algoritmos de Visión por Computadora y Aprendizaje Profundo permitirá al AUV identificar automáticamente signos de corrosión, fisuras, bioincrustaciones (biofouling) y daños estructurales en las imágenes capturadas por sus cámaras 4K y sensores ópticos (Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications"; Fuente: Arxiv, Título: "An interpretable approach to automating the assessment of biofouling in video footage"). Esto mejora drásticamente la eficiencia y la precisión en comparación con la inspección manual.

3. Gemelos Digitales (Digital Twins) para Mantenimiento Predictivo:

● **Explicación:** Un Gemelo Digital es una representación virtual de un objeto, sistema o proceso físico del mundo real. Se alimenta con datos en tiempo real del activo físico y utiliza modelos (físicos, de simulación, de datos) para reflejar su estado, predecir su comportamiento futuro y optimizar su rendimiento. En el contexto de infraestructuras, un gemelo digital puede simular el envejecimiento y la degradación.

● **Relevancia para Poseidón AUV:** Poseidón recopilará volúmenes masivos de datos sobre el estado de las infraestructuras. Estos datos serán la base para construir un Gemelo Digital de cada infraestructura inspeccionada. Mediante la aplicación de modelos de Machine Learning sobre estos datos históricos y en tiempo real, se podrán predecir las tasas de degradación de los materiales y recomendar proactivamente ventanas de mantenimiento (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy"; Fuente: Arxiv, Título: "Demonstration of a Standalone, Descriptive, and Predictive Digital Twin of a Floating Offshore Wind Turbine"). Esto transforma el mantenimiento de un modelo reactivo a uno predictivo, optimizando costos y extendiendo la vida útil de los activos.

1.2. Modelos y Metodologías Relevantes

El diseño de Poseidón AUV incorpora diversas metodologías y modelos avanzados que habilitan sus capacidades autónomas y analíticas:

● **Frameworks SLAM Basados en Sonar:** La investigación actual demuestra la eficacia de los frameworks SLAM que explotan la geometría del entorno submarino, especialmente con sonar de barrido lateral (SSS). Estos modelos representan las estructuras como secuencias de puntos de referencia individuales, permitiendo una localización y mapeo eficientes y precisos, superando soluciones anteriores en experimentos con hardware en bucle (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"). La integración de SSS con cámaras y sistemas de navegación inercial (INS) también se valida para la recopilación de datos de SLAM en escenarios de inspección de tuberías submarinas (Fuente: Arxiv, Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization").

● **Modelos de Aprendizaje Profundo para Procesamiento de Imágenes Submarinas:** Se emplearán arquitecturas de redes neuronales profundas para el análisis de imágenes. Esto incluye el uso de Convolutional Neural Networks (CNNs) para la segmentación y detección de objetos (Fuente: Arxiv,

Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization"), así como Vision Transformers (ViT) y Multilayer Perceptrons (MLP) para la reconstrucción de imágenes y la detección de anomalías como bioincrustaciones y defectos de red (Fuente: Arxiv, Título: "Anti-biofouling Lensless Camera System with Deep Learning based Image Reconstruction"; Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications"). En particular, enfoques como Component Features (ComFe) con DINOv2 Vision Transformer han demostrado un rendimiento mejorado y mayor interpretabilidad en la evaluación de bioincrustaciones (Fuente: Arxiv, Título: "An interpretable approach to automating the assessment of biofouling in video footage").

● **Técnicas de Fusión de Sensores y Aprendizaje Profundo para Navegación:** Para una navegación precisa y robusta, se implementará la fusión de sensores, combinando datos de un Doppler Velocity Log (DVL) y sensores inerciales. Además, se aplicarán enfoques de aprendizaje profundo para predecir vectores de aceleración del AUV basándose en mediciones de velocidad pasadas del DVL, lo que ha demostrado mejorar la estimación de la aceleración en más del 65% en comparación con métodos basados en modelos (Fuente: Arxiv, Título: "AUV Acceleration Prediction Using DVL and Deep Learning").

● **Modelos de Machine Learning para Gemelos Digitales y Análisis Predictivo:** La plataforma en tierra utilizará modelos de aprendizaje no supervisado para construir modelos de operación normal, detectar anomalías y diagnosticar fallas en tiempo real para el Gemelo Digital diagnóstico (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy"). Para el mantenimiento predictivo, se emplearán redes neuronales y técnicas de transferencia de aprendizaje para proyectar el comportamiento futuro de la infraestructura basándose en datos históricos y previsiones ambientales (Fuente: Arxiv, Título: "Demonstration of a Standalone, Descriptive, and Predictive Digital Twin of a Floating Offshore Wind Turbine").

1.3. Justificación Científica del Enfoque del Proyecto

El enfoque del proyecto Poseidón AUV es científicamente viable y prometedor debido a la madurez y la interconexión de los conceptos y metodologías descritos. La capacidad de un AUV para realizar SLAM de alta precisión en entornos submarinos (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"), complementada con la fusión de sensores avanzados (Fuente: Arxiv, Título: "AUV Acceleration Prediction Using DVL and Deep Learning"), resuelve el desafío fundamental de la navegación autónoma en ausencia de GPS.

La combinación de hardware de sensores de alta resolución (sonar, cámaras 4K, sensores de corrosión) con algoritmos de Visión por Computadora y Aprendizaje Profundo (Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications"; Fuente: Arxiv, Título: "An interpretable approach to automating the assessment of biofouling in video footage") permite una detección de anomalías automatizada y de alta precisión, superando las limitaciones de la inspección humana y los métodos tradicionales. La existencia de datasets específicos para la inspección de tuberías submarinas (Fuente: Arxiv, Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization") valida la aplicabilidad de estas técnicas en el dominio de interés.

Finalmente, la integración de estos datos en un Gemelo Digital y la aplicación de modelos de Machine Learning para el análisis predictivo (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy"; Fuente: Arxiv, Título: "Demonstration of a Standalone, Descriptive, and Predictive Digital Twin of a Floating Offshore Wind Turbine") representan un salto cualitativo hacia la optimización del mantenimiento. Este ecosistema de tecnologías, donde cada componente se beneficia y alimenta al siguiente, valida científicamente el camino propuesto para lograr una plataforma de inspección y mantenimiento submarino altamente eficiente, autónoma y predictiva.

2. Análisis del Estado del Arte

2.1. Técnicas y Enfoques Predominantes

El panorama actual de la inspección y mantenimiento submarino se caracteriza por un creciente interés en la automatización y la inteligencia artificial, buscando superar las limitaciones de los métodos tradicionales. Las técnicas y enfoques predominantes, según la literatura proporcionada, incluyen:

- **Inspección con AUVs y ROVs:** Los Vehículos Autónomos Submarinos (AUVs) y los Vehículos Operados Remotamente (ROVs) son las plataformas primarias para la inspección de infraestructuras submarinas. Se utilizan para diversas aplicaciones como encuestas oceanográficas, mapeo submarino e inspección de infraestructura (Fuente: Arxiv, Título: "AUV Acceleration Prediction Using DVL and Deep Learning"). En particular, los AUVs son vistos como clave para automatizar procesos en granjas de algas y acuicultura a escala industrial (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"; Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications").
- **SLAM para Navegación Submarina:** Dada la ausencia de GPS, el SLAM es un enfoque fundamental para la navegación autónoma. Se han desarrollado frameworks específicos que utilizan sonar de barrido lateral (SSS) para la localización y el mapeo en entornos estructurados, como granjas de algas, modelando elementos estructurales como cuerdas (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"). Además, se han creado datasets que combinan SSS, cámaras y sistemas de navegación inercial (INS) para SLAM en escenarios de inspección de tuberías submarinas (Fuente: Arxiv, Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization").
- **Visión por Computadora y Deep Learning para Detección de Anomalías:** El análisis de imágenes submarinas se beneficia significativamente del aprendizaje profundo. Esto incluye la detección de defectos en redes de acuicultura (bioincrustaciones, vegetación, agujeros) utilizando métodos basados en deep learning (Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications"). Para la evaluación de bioincrustaciones, se emplean técnicas de visión por computadora más avanzadas, como el enfoque de Component Features (ComFe) con modelos de base DINOv2 Vision Transformer, que ofrecen mayor interpretabilidad (Fuente: Arxiv, Título: "An interpretable approach to automating the assessment of biofouling in video footage").
- **Sistemas de Cámara Antifouling:** Para contrarrestar el problema de las bioincrustaciones en cámaras de monitoreo a largo plazo, se están investigando sistemas de cámara sin lentes que combinan materiales con alta resistencia inherente a las bioincrustaciones (ej. cobre) con tecnologías de visión por

computadora basadas en deep learning para la reconstrucción de imágenes (Fuente: Arxiv, Título: "Anti-biofouling Lensless Camera System with Deep Learning based Image Reconstruction").

● **Gemelos Digitales para Gestión de Activos Offshore:** La implementación de gemelos digitales está ganando terreno para el monitoreo, diagnóstico y mantenimiento predictivo de activos remotos, de alto valor y alto riesgo, como las turbinas eólicas marinas flotantes. Estos gemelos combinan datos en tiempo real con modelos, utilizando aprendizaje no supervisado para detectar anomalías y redes neuronales para predicciones (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy"; Fuente: Arxiv, Título: "Demonstration of a Standalone, Descriptive, and Predictive Digital Twin of a Floating Offshore Wind Turbine").

2.2. Limitaciones Identificadas y Brechas en la Investigación

A pesar de los avances, la investigación académica y la implementación práctica en el ámbito submarino enfrentan desafíos significativos:

- **Cuello de Botella en la Navegación Segura:** La implementación de AUVs se ve limitada por la necesidad de garantizar una navegación segura y estimaciones precisas de la pose del AUV en línea, especialmente en entornos complejos y estructurados (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring"). Esto implica la necesidad de sistemas SLAM más robustos y eficientes.
- **Precisión y Fiabilidad de la Navegación:** Aunque la fusión de sensores es común, la estimación del vector de aceleración del AUV a partir de mediciones de velocidad del DVL aún puede mejorarse para aumentar la precisión y fiabilidad de la navegación (Fuente: Arxiv, Título: "AUV Acceleration Prediction Using DVL and Deep Learning").
- **Escasez de Datasets Anotados para Inspección Real:** Existe una brecha significativa en la disponibilidad de datasets submarinos anotados que representen escenarios reales de inspección de tuberías. La mayoría de los benchmarks actuales son limitados, lo que dificulta el desarrollo y la validación de algoritmos de visión por computadora (Fuente: Arxiv, Título: "SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization").
- **Impacto de Bioincrustaciones en Sensores Ópticos:** Las bioincrustaciones en lentes y aperturas de cámaras submarinas son un problema persistente que impide la captura de imágenes claras y limita la observación a largo plazo (Fuente: Arxiv, Título: "Anti-biofouling Lensless Camera System with Deep Learning based Image Reconstruction").
- **Costos y Dependencia Humana de Métodos Actuales:** Los métodos de inspección y mantenimiento existentes, que dependen de buzos o ROVs operados remotamente, son costosos, requieren operadores altamente cualificados y conllevan riesgos humanos significativos (Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications").
- **Complejidad en la Implementación de Gemelos Digitales:** Aunque el concepto de gemelo digital es prometedor para activos offshore, su implementación práctica puede ser desafiante, especialmente en la integración de datos en tiempo real y la construcción de modelos de operación normal precisos (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy").

- **Interpretabilidad de los Modelos de IA:** En la evaluación de bioincrustaciones, se ha identificado la necesidad de modelos de IA más transparentes y con menos parámetros para comprender mejor qué regiones de la imagen contribuyen a la clasificación y cómo se llega a una conclusión (Fuente: Arxiv, Título: "An interpretable approach to automating the assessment of biofouling in video footage").

2.3. Posicionamiento e Innovación Clave del Proyecto

El proyecto Poseidón AUV se posiciona como una solución innovadora que aborda directamente varias de las limitaciones y brechas identificadas en el estado del arte, ofreciendo una propuesta de valor integral y de alto impacto:

- 1. Navegación Autónoma Avanzada y Robusta:** Poseidón AUV aborda el "cuello de botella en la navegación segura" (Fuente: Arxiv, Título: "Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring") mediante la implementación de algoritmos SLAM basados en sonar de barrido lateral y multihaz. Esto permite una localización precisa y el mapeo en entornos complejos sin necesidad de GPS, superando las capacidades de navegación de los AUVs actuales y mejorando la precisión y fiabilidad al incorporar técnicas avanzadas de estimación de aceleración (Fuente: Arxiv, Título: "AUV Acceleration Prediction Using DVL and Deep Learning").
- 2. Detección de Anomalías Multiespectral y Automatizada:** A diferencia de enfoques que se centran en un tipo específico de anomalía (ej., defectos de red o bioincrustaciones), Poseidón integra un conjunto de sensores de alta resolución (sonar, cámaras 4K, sensores de corrosión electromagnética) con un sistema de Detección de Anomalías mediante Computer Vision. Esto le permite identificar de forma autónoma y con alta precisión una gama más amplia de problemas (corrosión, fisuras, bioincrustaciones, daños estructurales), elevando la "precisión en la detección de defectos estructurales en un 50%" como objetivo cuantificable del proyecto. La capacidad de detectar corrosión electromagnéticamente y la posible integración de tecnologías anti-bioincrustaciones (Fuente: Arxiv, Título: "Anti-biofouling Lensless Camera System with Deep Learning based Image Reconstruction") ofrecen una ventaja significativa.
- 3. Mantenimiento Predictivo Integrado mediante Gemelo Digital:** La innovación clave de Poseidón radica en su enfoque holístico que trasciende la mera inspección. Al alimentar un "Gemelo Digital" con datos recopilados por el AUV y aplicar modelos de Machine Learning para el análisis predictivo, el proyecto aborda directamente la "complejidad en la implementación de gemelos digitales" (Fuente: Arxiv, Título: "Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy") y la necesidad de pasar de un mantenimiento reactivo a uno proactivo. Esto permite predecir la degradación de materiales y recomendar ventanas de mantenimiento óptimas, maximizando la vida útil de infraestructuras multimillonarias.
- 4. Reducción Drástica de Costos y Riesgos Humanos:** El proyecto aborda la "dependencia humana y los altos costos" de los métodos tradicionales (Fuente: Arxiv, Título: "Autonomous Underwater Robotic System for Aquaculture Applications"). Al automatizar la inspección y el mantenimiento menores, Poseidón AUV tiene como objetivo "reducir los costos de inspección submarina en un 40%" y "aumentar la frecuencia de las inspecciones en un 300%", disminuyendo drásticamente el riesgo para los buzos humanos y optimizando la eficiencia operativa.

En resumen, Poseidón AUV no solo implementa tecnologías de vanguardia de forma aislada, sino que las integra en una plataforma coherente y autónoma que ofrece una solución end-to-end para la inspección y mantenimiento submarino. Su principal propuesta de valor innovadora reside en la **convergencia sinérgica**

de navegación autónoma avanzada, percepción inteligente multisensor y un sistema de gemelo digital predictivo, creando una capacidad sin precedentes para la gestión proactiva de infraestructuras críticas sumergidas.

3. Fuentes y Referencias

Artículos Académicos Consultados

- [Arxiv] Side Scan Sonar-based SLAM for Autonomous Algae Farm Monitoring

URL: <https://arxiv.org/pdf/2509.26121v1>

- [Arxiv] SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization

URL: <https://arxiv.org/pdf/2401.17907v2>

- [Arxiv] AUV Acceleration Prediction Using DVL and Deep Learning

URL: <https://arxiv.org/pdf/2503.16573v1>

- [Arxiv] Anti-biofouling Lensless Camera System with Deep Learning based Image Reconstruction

URL: <https://arxiv.org/pdf/2410.01365v1>

- [Arxiv] Autonomous Underwater Robotic System for Aquaculture Applications

URL: <https://arxiv.org/pdf/2308.14762v2>

- [Arxiv] An interpretable approach to automating the assessment of biofouling in video footage

URL: <https://arxiv.org/pdf/2503.12875v2>

- [Arxiv] Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy

URL: <https://arxiv.org/pdf/2406.02775v1>

- [Arxiv] Demonstration of a Standalone, Descriptive, and Predictive Digital Twin of a Floating Offshore Wind Turbine

URL: <https://arxiv.org/pdf/2304.01093v1>

- [Arxiv] Energy-Efficient Federated Learning and Migration in Digital Twin Edge Networks

URL: <https://arxiv.org/pdf/2503.15822v1>