

Reporte de Fundamentación y Estado del Arte

Proyecto: Poseidón AUV: Plataforma Robótica Autónoma para Inspección y Mantenimiento de Infraestructura Submarina

Fecha de Generación: 24 de October de 2025

Reporte de Fundamentación para el Proyecto Poseidón AUV

1. Marco Teórico

1.1. Conceptos Fundamentales

El proyecto Poseidón AUV se asienta sobre pilares teóricos fundamentales que combinan la robótica submarina avanzada, la inteligencia artificial para la percepción y la autonomía, y la gestión inteligente de datos para el mantenimiento de infraestructuras críticas. Los conceptos más cruciales son:

- **Vehículos Autónomos Submarinos (AUV) y Sistemas Multi-sensor:** Los AUVs son plataformas robóticas capaces de operar de forma independiente bajo el agua, esenciales para tareas que son peligrosas o inaccesibles para humanos o vehículos controlados remotamente. Su capacidad operativa se ve amplificada por la integración de suites de sensores avanzadas. La literatura resalta el uso de AUVs equipados con una variedad de sensores, como cámaras, sonares (de barrido lateral y multihaz), y sistemas de navegación inercial, para la recopilación de datos de inspección y localización (Fuente: [Arxiv], Título: SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization).
- **Relevancia para Poseidón:** El AUV Poseidón es el corazón del proyecto, actuando como la plataforma de recopilación de datos y ejecución de tareas. Su diseño modular y la integración de sonar de barrido lateral y multihaz, cámaras 4K, sensores ópticos y de corrosión electromagnética, así como un brazo robótico, capitalizan directamente este concepto, permitiendo una inspección y monitoreo exhaustivos a profundidades y duraciones considerables.
- **Simultaneous Localization and Mapping (SLAM) en Entornos Submarinos:** SLAM es una técnica computacional que permite a un robot construir o actualizar un mapa de su entorno mientras, simultáneamente, estima su propia posición dentro de ese mapa. Esta capacidad es vital en entornos sin acceso a sistemas de posicionamiento global (como el GPS), como es el caso del subacuático. La robustez del SLAM es un desafío en el lecho marino debido a la escasez de hitos identificables y la baja resolución de ciertos datos (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM).

- **Relevancia para Poseidón:** La navegación autónoma basada en SLAM es una de las tecnologías clave de Poseidón. Permite al AUV operar sin depender de GPS y construir mapas 3D precisos de las infraestructuras y del lecho marino. Esto es fundamental para la precisión en la inspección y para el posterior análisis del gemelo digital, garantizando que los datos estén geo-referenciados con exactitud.
- **Inteligencia Artificial (IA) y Visión por Computadora para Percepción Submarina:** La IA, y específicamente el Deep Learning y la Visión por Computadora, se aplica para analizar datos visuales y acústicos con el fin de detectar objetos, segmentar imágenes e identificar anomalías. Aunque prometedor, su aplicación submarina se ve dificultada por la escasez de datasets anotados (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections). No obstante, se exploran métodos para superar esta limitación, como la generación de datos sintéticos o enfoques de detección "training-free" (Fuente: [Arxiv], Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds).
- **Relevancia para Poseidón:** Poseidón integra un sistema de Detección de Anomalías mediante Computer Vision, entrenado para identificar automáticamente signos de corrosión, fisuras, bioincrustaciones y daños estructurales. Esto transforma la inspección de una tarea manual y subjetiva a un proceso automatizado y objetivo, mejorando la precisión y la eficiencia.
- **Gemelos Digitales (Digital Twins) y Mantenimiento Predictivo:** Un Gemelo Digital es una representación virtual de un activo físico que se actualiza continuamente con datos en tiempo real y datos históricos. Permite monitorear la salud del activo, diagnosticar fallos y predecir su rendimiento futuro, facilitando un mantenimiento proactivo en lugar de reactivo (Fuente: [Arxiv], Título: A Systematic Review of Digital Twin-Driven Predictive Maintenance in Industrial Engineering).
- **Relevancia para Poseidón:** La plataforma de Gemelo Digital de Poseidón es el componente clave para la toma de decisiones. Los datos recopilados por el AUV alimentan este gemelo, sobre el cual se aplican modelos de Machine Learning para predecir la tasa de degradación de los materiales y recomendar proactivamente ventanas de mantenimiento. Esto optimiza la vida útil de las infraestructuras y reduce costos operativos.

1.2. Modelos y Metodologías Relevantes

La investigación académica proporciona las bases para los modelos y metodologías que el proyecto Poseidón AUV adoptará:

- **Algoritmos de SLAM (Simultaneous Localization and Mapping):**
- **Funcionamiento:** Los algoritmos SLAM utilizan flujos de datos de sensores (como sonar y unidades de medición inercial) para construir un mapa del entorno mientras se estima la trayectoria del vehículo. La detección de cierre de bucles (loop closure) es un componente crítico para corregir la deriva acumulada en la estimación de la posición, y se ha propuesto el uso de redes neuronales para mejorar esta detección en nubes de puntos batimétricas, superando la escasez de hitos distintivos (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM). Adicionalmente, se utilizan filtros de partículas (PF) para la fusión de datos de sonar, permitiendo una localización global robusta en entornos con baja densidad de infraestructura (Fuente: [Arxiv], Título: A Sonar-based AUV Positioning System for Underwater Environments with Low Infrastructure Density).

- **Relevancia para Poseidón:** Estos modelos son la base del software de navegación autónoma de Poseidón, permitiendo que el AUV opere de manera independiente y construya mapas 3D de alta precisión de las infraestructuras submarinas, lo cual es esencial para la inspección y el monitoreo detallado.

- **Redes Neuronales y Deep Learning para Visión por Computadora (Detección de Objetos y Segmentación):**

- **Funcionamiento:** Las redes neuronales profundas se entrenan con grandes conjuntos de datos para reconocer patrones complejos en imágenes y nubes de puntos, lo que permite la detección de objetos (e.g., tuberías, fallas) y la segmentación (e.g., aislar áreas de corrosión). Dada la escasez de datos submarinos reales, se exploran técnicas como las Redes Generativas Antagónicas (GANs) para crear datasets sintéticos y aumentar la cantidad de datos de entrenamiento disponibles (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections).

- **Relevancia para Poseidón:** Estos modelos son fundamentales para el sistema de Detección de Anomalías mediante Computer Vision. Permiten el procesamiento automático de las imágenes 4K y los datos de sonar para identificar corrosión, fisuras, bioincrustaciones y otros daños, transformando la inspección visual en un proceso objetivo y eficiente.

- **Modelos de Machine Learning para Análisis Predictivo y Detección de Anomalías:**

- **Funcionamiento:** Estos modelos analizan datos históricos y en tiempo real para aprender patrones de comportamiento normal y detectar desviaciones (anomalías) que podrían indicar un fallo inminente. Se utilizan métodos de aprendizaje no supervisado para construir modelos de operación normal y detectar anomalías en tiempo real (Fuente: [Arxiv], Título: Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy). Para la predicción a largo plazo, se emplean modelos avanzados como los basados en transformadores, capaces de gestionar la complejidad de los datos a lo largo de extensos períodos operativos y cuantificar la incertidumbre de las predicciones (Fuente: [Arxiv], Título: A Digital Twin Framework Utilizing Machine Learning for Robust Predictive Maintenance: Enhancing Tire Health Monitoring).

- **Relevancia para Poseidón:** Estos modelos son el cerebro de la plataforma de Gemelo Digital. Al aplicarlos a los datos recopilados por el AUV (incluyendo mediciones de corrosión), Poseidón puede predecir la tasa de degradación de los materiales y optimizar las estrategias de mantenimiento, pasando de un modelo reactivo a uno predictivo y proactivo.

1.3. Justificación Científica del Enfoque del Proyecto

El enfoque del proyecto Poseidón AUV es científicamente viable y prometedor debido a la convergencia y madurez relativa de los conceptos y metodologías descritos.

La integración de un AUV con una **suite de sensores avanzados** no es solo una capacidad técnica, sino una validación científica de que la adquisición de datos de alta calidad es el primer paso indispensable para cualquier análisis robusto (Fuente: [Arxiv], Título: SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization). La capacidad de Poseidón para operar a 500 metros y durante 24 horas, junto con la diversidad de sus sensores (sonar, ópticos, corrosión), asegura una recopilación de datos sin precedentes en términos de alcance y granularidad.

La **navegación autónoma basada en SLAM** es un requisito crítico en el entorno submarino sin GPS. La investigación ha demostrado la viabilidad de algoritmos SLAM robustos, incluso con las limitaciones de los datos batimétricos y la escasez de hitos (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM). Poseidón capitaliza estos avances para garantizar una localización precisa y una capacidad de mapeo detallada, lo cual es fundamental para la coherencia del Gemelo Digital.

La **percepción autónoma mediante Computer Vision e IA a bordo** aborda la necesidad de una detección eficiente y precisa de anomalías. Aunque la escasez de datasets es un desafío reconocido (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections), la propia capacidad de Poseidón para generar datos reales de alta calidad durante sus misiones de inspección mitigará esta brecha, permitiendo el entrenamiento y refinamiento de modelos específicos para sus casos de uso. Los avances en la detección 3D de objetos a partir de sonar (Fuente: [Arxiv], Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds) también validan la promesa de la IA para la interpretación de datos acústicos complejos.

Finalmente, la **plataforma de Gemelo Digital y Análisis Predictivo** representa la culminación de los datos y el análisis. La aplicación de modelos de Machine Learning (incluido el aprendizaje no supervisado para la detección de anomalías y los modelos de transformadores para la predicción) sobre un Gemelo Digital es una metodología probada en diversas industrias para optimizar el mantenimiento y la vida útil de los activos (Fuente: [Arxiv], Título: Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy; [Arxiv], Título: A Digital Twin Framework Utilizing Machine Learning for Robust Predictive Maintenance). El enfoque de Poseidón extiende esta promesa a las infraestructuras submarinas, transformando un modelo reactivo en uno proactivo y predictivo, lo que es una dirección clara en la evolución de la ingeniería industrial.

En síntesis, el proyecto Poseidón AUV integra y avanza sobre un conjunto de tecnologías y metodologías científicamente validadas, combinando la adquisición de datos de vanguardia, la autonomía inteligente y la analítica predictiva para ofrecer una solución integral y altamente innovadora.

2. Análisis del Estado del Arte

2.1. Técnicas y Enfoques Predominantes

La investigación actual en el ámbito de la inspección y el mantenimiento submarino se centra en varios enfoques tecnológicos clave, reflejados en los artículos proporcionados:

- **Vehículos Autónomos Submarinos (AUVs) con Suites Multi-sensor:** Un enfoque predominante implica el despliegue de AUVs equipados con diversas configuraciones de sensores para la recopilación de datos. Estos incluyen cámaras RGB, sonares de barrido lateral y multihaz (MBES), y sistemas de navegación inercial (INS) para misiones como la inspección de oleoductos (Fuente: [Arxiv], Título: SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization). Los sonares de barrido frontal (FSD) también se utilizan para la localización en tiempo real en entornos con baja densidad de infraestructura (Fuente: [Arxiv], Título: A Sonar-based AUV Positioning System for

Underwater Environments with Low Infrastructure Density).

- **Desarrollo y Utilización de Datasets Submarinos para IA:** La comunidad investigadora reconoce la necesidad crítica de datasets submarinos para el entrenamiento y evaluación de modelos de IA. Se han creado datasets específicos para tareas de SLAM, detección de objetos y segmentación de imágenes en escenarios de inspección de tuberías (Fuente: [Arxiv], Título: SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization). Además, se ha explorado la generación de datasets virtuales utilizando técnicas como las Redes Generativas Antagónicas (GANs) para superar la escasez de datos reales (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections). La sistematización y caracterización de los datasets de imágenes de sonar existentes es también un área de trabajo activa (Fuente: [Arxiv], Título: Sonar Image Datasets: A Comprehensive Survey of Resources, Challenges, and Applications).

- **Algoritmos de SLAM para Navegación Autónoma Submarina:** Para la localización y mapeo autónomo de AUVs, los marcos SLAM son fundamentales. Se investigan soluciones que abordan la robustez de la asociación de datos para la detección de cierre de bucles (loop closure) en nubes de puntos batimétricas, utilizando arquitecturas de redes neuronales para mejorar el rendimiento en comparación con métodos más tradicionales (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM). Los filtros de partículas se emplean para fusionar datos de sonar y lograr una localización global en tiempo real (Fuente: [Arxiv], Título: A Sonar-based AUV Positioning System for Underwater Environments with Low Infrastructure Density).

- **Detección de Objetos 3D y Análisis de Imágenes con IA:** Se aplican modelos de Deep Learning para la detección, clasificación y segmentación de objetos en imágenes y nubes de puntos submarinas. Para la detección de objetos 3D a partir de nubes de puntos de sonar, se comparan enfoques de Deep Learning entrenados con datos sintéticos y sistemas basados en plantillas geométricas, demostrando la viabilidad de ambos (Fuente: [Arxiv], Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds).

- **Gemelos Digitales (Digital Twins) para Mantenimiento Predictivo:** La implementación de Gemelos Digitales se está consolidando como una estrategia clave para el mantenimiento predictivo en ingeniería industrial, incluyendo activos de alto valor como las turbinas eólicas flotantes offshore. Estos gemelos combinan datos en tiempo real y modelos para monitorear, detectar anomalías y diagnosticar fallos utilizando métodos de Machine Learning (como aprendizaje no supervisado) (Fuente: [Arxiv], Título: Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy). Se están desarrollando marcos de Gemelos Digitales que emplean técnicas de reducción de datos y modelos basados en transformadores para predicciones a largo plazo y toma de decisiones estratégicas (Fuente: [Arxiv], Título: A Digital Twin Framework Utilizing Machine Learning for Robust Predictive Maintenance: Enhancing Tire Health Monitoring).

2.2. Limitaciones Identificadas y Brechas en la Investigación

La investigación actual, si bien ha logrado avances significativos, también revela varias limitaciones y brechas críticas que impiden una adopción más amplia y eficiente de estas tecnologías:

- **Escasez de Datasets Submarinos Anotados y Dificultad de Adquisición:** Una barrera fundamental para el avance del Deep Learning en aplicaciones submarinas es la dificultad y el costo prohibitivo de

obtener suficientes datos reales, bien anotados, para el entrenamiento de modelos. Esto es especialmente cierto para imágenes de sonar y datos batimétricos, lo que frena el desarrollo de modelos robustos (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections; [Arxiv], Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds; [Arxiv], Título: Sonar Image Datasets: A Comprehensive Survey of Resources, Challenges, and Applications).

● **Desafíos en la Robustez de SLAM en Entornos Submarinos:** Los algoritmos SLAM se enfrentan a desafíos inherentes al entorno submarino, como la escasez de hitos identificables en el lecho marino, la baja resolución de los datos de los ecosondas multihaz (MBES) y la propensión a una gran deriva en las estimaciones de navegación por estima. Estos factores complican la asociación de datos y la detección fiable de cierre de bucles (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM). La localización en entornos con una distribución escasa de infraestructura humana también representa un reto significativo para la robustez de los sistemas (Fuente: [Arxiv], Título: A Sonar-based AUV Positioning System for Underwater Environments with Low Infrastructure Density).

● **Problemas de Transferencia y "Domain Shift" en Modelos de Deep Learning:** Los modelos de Deep Learning entrenados con datos sintéticos o en entornos más estructurados muestran una caída significativa en el rendimiento cuando se aplican a datos submarinos reales, debido al fenómeno del "domain shift" (cambio de dominio). Esto indica una brecha entre el rendimiento en entornos simulados y el mundo real (Fuente: [Arxiv], Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds).

● **Complejidad en la Implementación y Escalabilidad de Gemelos Digitales:** Aunque el concepto de Gemelo Digital es muy prometedor, su implementación en escenarios industriales complejos, especialmente para activos remotos y de alto valor, presenta desafíos. Requiere técnicas de reducción de datos para manejar grandes volúmenes de información a lo largo del tiempo y modelos predictivos capaces de ofrecer inferencias rápidas y fiables en tiempo real (Fuente: [Arxiv], Título: Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy; [Arxiv], Título: A Digital Twin Framework Utilizing Machine Learning for Robust Predictive Maintenance).

● **Fragmentación de Soluciones y Falta de Enfoques Integrales:** Si bien existen avances en componentes individuales (AUVs, SLAM, IA, Gemelos Digitales), a menudo falta una solución integrada que combine de manera sinérgica estas tecnologías para abordar el ciclo completo de inspección, diagnóstico y mantenimiento predictivo en infraestructuras submarinas de forma holística.

2.3. Posicionamiento e Innovación Clave del Proyecto

El proyecto Poseidón AUV se posiciona como una solución innovadora y transformadora, abordando directamente las limitaciones y brechas identificadas en el estado del arte a través de una integración sinérgica de tecnologías avanzadas. Su propuesta de valor reside en ofrecer una plataforma robótica autónoma integral que no solo recopila datos de alta calidad, sino que también los procesa inteligentemente para el mantenimiento predictivo.

Poseidón aborda varias de las limitaciones críticas:

1. **Superación de la Escasez de Datasets y el "Domain Shift":** La investigación destaca la dificultad de obtener datasets submarinos anotados y el problema del "domain shift" al usar datos sintéticos para entrenar modelos de IA (Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections; [Arxiv],

Título: Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds). Poseidón aborda esto de dos maneras:

- **Generación de Datos Propios y de Alta Calidad:** Con su suite de sensores avanzados (Sonar de Barrido Lateral y Multihaz, Cámaras 4K, Sensores de Corrosión Electromagnética), Poseidón generará activamente sus propios datasets de alta resolución y relevancia directa para las infraestructuras que inspecciona. Esto permite entrenar y validar modelos de Computer Vision con datos reales y específicos de la misión, mitigando el "domain shift".
- **IA a Bordo Adaptada:** El sistema de Detección de Anomalías mediante Computer Vision a bordo se entrenará y refinará continuamente con los datos capturados, permitiendo una adaptación más rápida a las condiciones submarinas reales y una mejora progresiva en la precisión de la detección de defectos estructurales en un 50%.

2. **Navegación Autónoma Robusta en Entornos Desafiantes:** La limitación de los algoritmos SLAM en entornos submarinos con escasez de hitos, baja resolución de datos y derivas considerables (Fuente: [Arxiv], Título: Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM; [Arxiv], Título: A Sonar-based AUV Positioning System for Underwater Environments with Low Infrastructure Density) es directamente abordada por Poseidón.

- **SLAM Multimodal Avanzado:** La implementación de algoritmos SLAM que fusionan datos de múltiples sensores (sonar, ópticos, inerciales) permite una localización y mapeo precisos incluso en ausencia de GPS y en entornos con baja densidad de infraestructura. Esto asegura la construcción de modelos 3D detallados y la capacidad del AUV para navegar de forma segura y eficiente.

3. **Solución Integral y Proactiva para el Mantenimiento Predictivo:** La fragmentación de soluciones y la complejidad de implementar Gemelos Digitales para mantenimiento predictivo (Fuente: [Arxiv], Título: Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy; [Arxiv], Título: A Systematic Review of Digital Twin-Driven Predictive Maintenance in Industrial Engineering) es la brecha más significativa que Poseidón supera.

- **Ecosistema de Gemelo Digital Holístico:** Poseidón no es solo un AUV; es una plataforma que integra la adquisición de datos, la percepción autónoma y la analítica avanzada en un Gemelo Digital coherente. Al alimentar este gemelo con datos históricos y en tiempo real, y aplicar modelos de Machine Learning para predecir la degradación de materiales, el proyecto transforma el mantenimiento de reactivo a predictivo. Esta integración es la verdadera innovación, ya que pocos sistemas actuales ofrecen una solución completa desde la inspección autónoma hasta la recomendación de mantenimiento proactivo, optimizando la vida útil de infraestructuras multimillonarias.

4. **Reducción Drástica de Costos y Riesgos Operacionales:** Más allá de las innovaciones tecnológicas, la propuesta de valor de Poseidón se traduce en beneficios tangibles que abordan las ineficiencias de los métodos tradicionales (buzos y ROVs operados remotamente). Al automatizar las inspecciones y tareas de mantenimiento menores, el proyecto busca reducir los costos de inspección submarina en un 40% y aumentar la frecuencia de las inspecciones en un 300%, mejorando significativamente la seguridad y la detección temprana de fallos, lo cual es un objetivo constante en la evolución de los vehículos submarinos autónomos

(Fuente: [Arxiv], Título: Virtual Underwater Datasets for Autonomous Inspections).

En resumen, la principal propuesta de valor innovadora de Poseidón AUV radica en su **enfoque sistémico e integral**, que fusiona un hardware AUV de vanguardia con inteligencia artificial a bordo para la percepción y navegación, y una plataforma de Gemelo Digital en tierra para el análisis predictivo. Esta arquitectura holística no solo resuelve las limitaciones actuales de datos, autonomía y precisión, sino que también redefine el paradigma de inspección y mantenimiento de infraestructuras submarinas, pasando de un modelo costoso y reactivo a uno eficiente, seguro y proactivo.

3. Fuentes y Referencias

Artículos Académicos Consultados

- [Arxiv] SubPipe: A Submarine Pipeline Inspection Dataset for Segmentation and Visual-inertial Localization

URL: <https://arxiv.org/pdf/2401.17907v2>

- [Arxiv] Virtual Underwater Datasets for Autonomous Inspections

URL: <https://arxiv.org/pdf/2209.06013v2>

- [Arxiv] Data-driven Loop Closure Detection in Bathymetric Point Clouds for Underwater SLAM

URL: <https://arxiv.org/pdf/2209.08578v1>

- [Arxiv] A Sonar-based AUV Positioning System for Underwater Environments with Low Infrastructure Density

URL: <https://arxiv.org/pdf/2405.01971v1>

- [Arxiv] Towards Training-Free Underwater 3D Object Detection from Sonar Point Clouds: A Comparison of Traditional and Deep Learning Approaches

URL: <https://arxiv.org/pdf/2508.18293v1>

- [Arxiv] Sonar Image Datasets: A Comprehensive Survey of Resources, Challenges, and Applications

URL: <https://arxiv.org/pdf/2510.03353v1>

- [Arxiv] Diagnostic Digital Twin for Anomaly Detection in Floating Offshore Wind Energy

URL: <https://arxiv.org/pdf/2406.02775v1>

- [Arxiv] A Digital Twin Framework Utilizing Machine Learning for Robust Predictive Maintenance: Enhancing Tire Health Monitoring

URL: <https://arxiv.org/pdf/2408.06220v1>

- [Arxiv] A Systematic Review of Digital Twin-Driven Predictive Maintenance in Industrial Engineering: Taxonomy, Architectural Elements, and Future Research Directions

URL: <https://arxiv.org/pdf/2509.24443v1>